### ML 無監督式學習

### (Machine Learning, Unsupervised Learning)


利用 KMeans 將花(Iris)分成三種聚類 point fit 到模型裡面後,scatterplot 呈現出結果




#### 評估聚類 Evaluating a Clustering

#### 慣性(Inertia)評估最佳聚類數量(KMeans)

慣性越小聚類越密集,而 KMeans 開始緩降為最佳解(紅框) 下圖,利用交叉表(cross-tabulation)評估聚類分布狀況(紅框) 評估花及品種是否有對應






#### 優化調整類組 Transforming Features for Better Clusterings

#### 假設交叉表分布沒有對應

# 先用 StandarScaler 或 Normalizer 與 KMeans 建構一個 pipeline

即可將資料標準化在分組,調整資料


下圖為優化後的聚類,交叉表(魚的品種)相互對應



# t-SNE 與層次聚類視覺化

### Visualization with Hierarchical Clustering and t-SNE


Normalize 資料後用 dendrogram 視覺化可用 fcluster 提取特定高度的聚類(下圖高度為 6)






#### t-SNE 視覺化





### PCA 降維 Decorrelating Data and Dimension Reduction

# 先用皮爾森(Pearson Correlation)做 scatter plot 接著 PCA 降維(下圖)





### 內在維度 Intrinsic Dimension


# 資料先 PCA(箭頭為 Pearson 的值>0) 再做 StandardScaler 跟 PCA 的 pipeline

# 可看出 X=2 (下圖紅線右邊)PCA 特徵沒有顯著差異

表示內在維度為2

X=2,3 沒有顯著差異,可用 PCA 降維至 2 (PCA(n\_components=2))






#### PCA 降維,做 Pipeline (TruncatedSVD & KMeans)


再帶入得到結果(下圖)

PCA 維度降到 50,總共6組 (資料為維基百科熱門標題文章)




#### 非負矩陣降維 NMF

# 資料為調查安海瑟薇跟丹佐華盛頓的文章特性 下圖紅框可看出 3 值最高 也就是 3 為主要重建(construct)文章的部分



## 用 iloc 把 3 的資料提取出來 發現安海瑟威跟丹佐華盛頓的文章 主要都具有以下特徵 (紅框)



#### 利用 NMF 建置推薦系統

(資料為先前使用的熱門維基百科文章) 資料標準化後,利用.dot (餘弦定理)找出跟西羅有相關的文章(紅框) 下兩圖概念相同

根據喜愛的音樂家,利用.dot,推薦有相關聯的音樂家

